

无教师潜在自蒸馏与类可分表示：轻量级物联网攻击检测

****原文题目**:** Teacher-free Latent Self-distillation and Class-separable Representations for Lightweight IoT Attack Detection

****作者**:** Phai Vu Dinh, Diep N. Nguyen, Dinh Thai Hoang, Marwan Krunz, Quang Uy Nguyen, Son Pham Bao, Eryk Dutkiewicz

****arXiv**:** 2403.15509v3 [cs.CR], 2026 年 8 月 20 日

****许可**:** CC BY 4.0

****声明**:** 非官方中文译本

摘要

知识蒸馏 (Knowledge Distillation, KD) 已被广泛用于通过将大型教师模型的软标签知识迁移到学生模型来改进轻量级人工智能模型。然而, 现有 KD 方法主要面向图像领域, 而非轻量级物联网设备; 它们往往难以对不同攻击类型保持良好分离的特征表示, 尤其是在类别数增加且攻击行为更加多样时。本文提出一种基于孪生自编码器 (Twin Autoencoder, TAE) 的新型无教师潜在自蒸馏框架。TAE 不依赖外部教师, 而是通过对潜在表示进行确定性变换生成内在的、按类别的潜在表示, 称为类自适应目标表示 (class-adaptive target representation, CATR); 它充当类似 KD 中软标签的目标表示。随后, 解码器学习重构 CATR, 从而促进所得解码器表示的类别分离。

TAE 训练完成后, 训练样本和测试样本均通过解码器, 以获得各自的表示。这些表示再作为决策树 (Decision Tree, DT) 等传统分类器的输入, 用于分类; 这样既能提高良性样本与攻击样本之间的区分能力, 又能保持适合物联网部署的轻量化设计。我们从理论上推导了实现完美类别分离的条件, 并证明较低的经验风险会带来更好的表示, 同时确定了 TAE 的经验风险严格低于使用固定类别中心的模型的条件。在覆盖物联网僵尸网络、网络入侵检测、恶意软件、云 DDoS 以及合成多分类数据的 13 个网络安全数据集上进行的大量实验表明, TAE 在物联网攻击检测中的平均准确率最高可达 96.1%, 在云入侵检测中可达 98.7%。TAE 的模型大小仅为 1 MB, 单样本推理速度超快 ($0.26 \mu s$), 为现实网络安全和物联网系统提供了实用且可扩展的解决方案。

****关键词 (Index Terms)****——知识蒸馏 (knowledge distillation), 自蒸馏 (self-distillation), 学生-教师学习 (student-teacher learning), 自编码器 (autoencoder), 入侵检测 (intrusion detection), 物联网 (IoT)。

1. 引言

入侵检测系统 (Intrusion Detection System, IDS) 对于数字时代保护物联网 (Internet of Things, IoT) 信息系统至关重要 [1], [2]。然而, 由于两个关键因素, 构建有效的物联网 IDS 仍然很有挑战。第一, 随着攻击类别的多样性和数量不断增长, 为物联网入侵检测学习具有判别性的表示变得日益困难。每年都会出现数以千计的新漏洞、恶意软件家族和攻击变种 [3], 扩大了物联网 IDS 必须区分的行为范围。随着攻击类别增多, 类别边界可能变得不再清晰, 因为不同攻击可能产生高度相似的网络流量模式。例如, 物联网数据集 [4] 包含超过 1,500 个 Mirai 僵尸网络变体, 其中许多仅在细微行为细节上有所不同。此外, 攻击者采用加密通信、资源仿真行为等规避技术, 进一步降低了攻击类别之间的可区分性。因此, 对现代物联网 IDS 而言, 学习既能保持类内一致性 (即同一类别的样本保持接近), 又能维持强类间可分性 (即不同类别的样本保持充分分离) 的特征表示, 仍是一项重大挑战。若不能达到这些性质, 分类准确率会下降, 误报率会升高。第二, IDS 不仅要能部署在服务器上, 也要能部署在资源受限的物联网设备上 [5]。由于内存和计算能力有限 [6], 这些设备无法支持高复杂度模型, 因此轻量而准确的检测方法至关重要。

相关工作

机器学习 (Machine Learning, ML) 通过学习网络流量模式来分类新的输入数据, 在 IDS 的成功中发挥了关键作用 [7]。然而, 决策树、支持向量机和随机森林等传统 ML 分类器可能难以应对复杂的网络安全数据 [8], [6], 从而导致较低的检测准确率。在 ML 技术中, 表示学习 (representation learning, RL) 是实现物联网设备有效 IDS 的关键方法, 因为它把复杂输入数据转换为便于后续攻击检测的抽象特征 [9]。但是, RL 模型在多类别分类任务上往往表现不佳 [10]。AlexNet、VGG、ResNet [11] 等很深的网络, 以及 Transformer (MLP [12]、1DCNN [13]) 能够在大量类别上取得很高的

分类准确率，但其规模过大，不适合计算资源有限的物联网设备 [14]。

许多 RL 模型依靠自编码器 (Autoencoder, AE) 的瓶颈层把输入数据映射为瓶颈处的潜在向量 [6], [15], [8], [16], [17]。AE 模型通常不需要数百万个参数，同时可以在物联网设备上实现较高的攻击检测准确率 [6]。Luo 等人 [18] 提出卷积稀疏自编码器 (Convolutional Sparse Auto-Encoder, CSAE)，利用卷积 AE 的结构分离特征图以进行表示学习，且 CSAE 编码器可作为预训练模型。文献 [8] 引入多分布自编码器 (Multi-Distribution Auto-Encoder, MAE) 和多分布变分自编码器 (Multi-Distribution Variational Auto-Encoder, MVAE)，通过在损失函数中加入惩罚项，旨在把良性数据和恶意数据投影到紧密分离的区域。CSAE、MAE 和 MVAE 都使用 AE 损失中的正则项来约束并分离不同类别的表示。然而，AE 中的正则项与重构项之间存在权衡，往往使训练更困难。文献 [6] 提出约束孪生变分自编码器 (Constrained Twin Variational AE, CTVAE)，在潜在空间中从可分离的高斯分布生成不同类别的数据样本，再把不同类别的输入数据投影到这些可分离的高斯分布以获得数据表示。但是，和各种变分自编码器 (Variational Auto-Encoder, VAE) 一样，CTVAE 通常受到后验坍缩 (posterior collapse) 问题的影响 [19]。当 CTVAE 损失中的 KL 散度项变为零时，就会发生后验坍缩；此时用于在潜在空间生成不同类别样本的输入信息不足。这很可能消除了同一类别内数据样本之间的欧氏距离关系，使所得分布不再遵循输入数据，进而降低使用这些模型数据表示时的分类准确率。此外，CSAE [18]、MAE、MVAE [8] 和 CTVAE [6] 等 AE 模型可能难以处理类别很多的训练集。监督式表示学习模型中使用的传统固定码字也可能无法有效分离不同类别的数据样本。这些码字 (即独热编码) 表示某一类别的目标向量 [20], [21]，但与训练数据的特征没有关系。

知识蒸馏 (KD) 被广泛用于基于表示学习的轻量级物联网 IDS [22]。KD 通常需要先在大规模数据集上训练大型教师模型，再将软标签知识迁移给物联网客户端。软标签是教师对所有类别产生的概率分布；与硬类别 (独热编码) 标签相比，它通过表示教师对各类别的置信度而提供更丰富的信息。然而，维护这类大型教师模型会增加计算成本，引入多阶段训练复杂度，并限制资源受限设备上物联网学生模型的可扩展性。

近年来，自蒸馏 (self-distillation, SD) 成为机器学习中受到关注的技术：模型使用自身之前的输出 (或中间表示) 作为软目标重新训练，以指导并改善模型性能。文献 [23] 提出 SDSSL，旨在使较低层与最终层的表示对齐，从而改善不同类别数据的线性可分性。ATAS [24] 更进一步，在所有尺度上整合全局到局部、局部到局部及全局到全局的蒸馏，以细化特征表示。类似地，COSMOS [25] 构建全局和局部输入视图进行 SD，并使用交叉注意力模块学习多模态表示。SDSSL、ATAS 和 COSMOS 在图像表示任务中表现出良好前景，因为空间信息与任务高度相关。然而，物联网数据通常缺少固有的空间结构，这可能限制这些方法为下游分类任务学习表示的有效性。此外，这些方法可能并不适合便携式物联网设备有限的计算能力。

特别是，文献 [2] 提出了 TBCLNN，一种基于自知识蒸馏的轻量级物联网 IDS。TBCLNN 使用二进制 Harris Hawk 优化算法 (binary Harris Hawk optimization, bHHO) 降低流量特征维数，并使用块卷积 (TBC) 这一轻量卷积操作设计轻量神经网络。与 TBCLNN 不同，本文采用了另一条路线：不是直接把自蒸馏用于分类，而是专注于基于 SD 的表示学习。本文方法通过学习更可分的数据表示，处理物联网数据不断增加的复杂性，尤其是在类别数极大时。与推理时需要使用整个模型的传统深度模型不同，本文方法只使用部分轻量级网络来提取紧凑且有判别性的表示。该轻量表示提取器可以与决策树 (DT) 等轻量传统分类器结合，在保持低计算复杂度和小模型规模、适合物联网设备的同时实现较高分类准确率。

总体而言，上述方法往往依赖预定义的目标，例如独热向量、固定码字或人工指定的潜在分布。这些目标独立于训练数据分配，因此无法捕捉类别之间的内在关系。随着攻击类别增加，把多样的类别分布映射到预定义目标变得越来越困难，导致学习到的特征空间中类别簇不够紧凑、不同攻击类别之间的分离度降低。于是不同类别的样本可能在潜在空间重叠，降低下游分类器的有效性。这一局限促使我们使用自蒸馏：目标表示直接从数据中学习，而不是预先定义。通过从自身的潜在表示生成依赖类别的软标签，自蒸馏框架能够动态构造更能反映数据内在结构的判别性目标。类别数增多时，这种自适应软标签尤其有价值，能够在不需要大型教师模型或显著增加模型复杂度的情况下改善类别分离。

本文提出一种基于孪生自编码器 (TAE) 的无教师潜在自蒸馏框架。TAE 不依赖外部教师，而是学习内在的按类别潜在表示，并将其作为类自适应目标表示 (CATR) 来指导解码器。这种设计无需教师模型额外开销即可学习判别性表示。

实验在多种网络安全数据集上开展，包括 7 个物联网僵尸网络数据集 [4]、2 个网络 IDS 数据集 [32], [33]、3 个恶意软件数据集 [34]、1 个云 DDoS 数据集 [35]，以及用于增加训练类别数的 10 个人工数据集。结果表明，本文方法优于先进自蒸馏方法 (SDSSL [23]、ATAS [24]、COSMOS [25])、表示学习模型 (CTVAE [6]、MAE、MVAE [8]、CSAEC [18])、传统分类器 (XGBoost [26], [1]、SVM、DT、RF、1D-CNN 和 MLP)、基于 MLP [12] 和 1D-CNN [13] 的 Transformer 分类器，以及包括独热编码、Hadamard 码 [20], [21] 和 MAE 码字 [8] 在内的硬编码方法。本文 TAE 与相关方法的比较见表 1。

主要贡献

- ☐ 提出一种基于 TAE 的无教师潜在蒸馏框架。不使用显式教师模型提供软标签，TAE 编码器对潜在表示进行确定性变换以生成 CATR；解码器学习从 CATR 重构输入，为下游任务产生判别性表示。
- ☐ 从理论上推导完美类别分离的条件，并证明较低经验风险可带来更好的表示，确定了 TAE 的经验风险严格低于使用固定类别中心的 MLP [36]，[30] 和 MAE [8] 的情形。TAE、CTVAE 和 MAE 的测试复杂度相同，即 $\mathcal{O}(N_T d^2)$ ，适合轻量级物联网设备。实验表明，TAE 适合网络安全应用和潜在的物联网系统：模型大小约 1 MB，提取单个数据样本的平均运行时间约为 0.26 μ s。
- ☐ 证明在提高使用 TAE 数据表示的分类器准确率方面，TAE 的 CATR 优于传统固定码字，包括独热编码、Hadamard [20]，[21]、MAE 码字 [8]，以及使用深度 MLP 和 ResNet 教师的 KD 软标签 [22]。使用 TAE 的均值作为固定码字也能提高分类准确率。
- ☐ 在多种网络安全数据集上进行大量实验，包括 7 个物联网僵尸网络、2 个网络入侵检测、3 个恶意软件、1 个云 DDoS 和 10 个用于评估训练类别数增加时性能的合成数据集。TAE 在物联网攻击检测中平均准确率最高达 96.1%，在云入侵检测中达 98.7%，超过相关模型。合成数据集实验还表明，TAE 能把原始数据有效映射到低维潜在空间，且类别数增加时不同类别样本变得越来越可分。

本文其余部分安排如下：第 II 节介绍所提架构和模型，第 III 节提供理论分析，第 IV 节介绍实验设置，第 V 节给出实验结果与讨论，第 VI 节讨论 TAE 的特性，最后第 VII 节总结全文并概述未来研究方向。

II. 孪生自编码器

方法：TAE (Twin Autoencoder)

A. TAE 架构

如图 1(a) 所示，TAE 由三个网络组成：编码器、两用网络 (hermaphrodite) 和解码器。编码器把第 i 个输入样本 $x(i)$ 映射为潜在向量 $e(i)$ 。不同于独热码或 Hadamard 码等传统固定码字（它们为同一类别内的每个样本分配相同的预定义向量），本文的类自适应目标表示 (CATR) 依赖样本，定义为

$$z(i, c) := e(i, c) + v(c) \quad (1)$$

其中， $e(i, c)$ 表示样本 $x(i, c)$ 的潜在表示， $v(c)$ 表示依赖类别的变换向量。因此，同一类别的样本可以具有不同的 CATR，而 $v(c)$ 随类别变化（见表 II）。训练时，类别标签 c 只用于通过相应的变换向量 $v(c)$ 构造 CATR。推理时类别标签不可用，也不需要类别标签；新的输入 x 直接送入训练好的解码器，得到最终重构表示 $z(i)$ （图 1(b)）。

两用网络连接编码器和解码器，因此同时承担解码和编码作用。作为解码器，它使用可分向量 $z(i)$ 把输入重构为 $x(i)$ ；作为编码器，它把可分向量 $z(i)$ 映射到新空间 $x(i)$ 。TAE 解码器试图把两用网络的输出投影到 CATR，得到 $z(i)$ 。由于 $z(i)$ 是从 CATR 重构而来，称为重构表示。重构表示作为 TAE 后续检测模型的最终表示。

表 II：TAE 方法与分析中使用的符号。

符号	定义		
$x(i)$	第 i 个输入样本		
$x(i, c)$	属于类别 c 的第 i 个输入样本		
X	数据集 $\{x(i)\}_{i=1}^n$		
C	类别集合， $\mathcal{C}$	C	$\mathcal{C}$ 表示类别数
n_c	属于类别 c 的样本数		
d	输入表示的维度		

符号	定义		
$\hat{e}(i, c)$	TAE 编码器产生的 $\hat{x}(i, c)$ 的潜在表示		
μ^c	类别 c 的潜在表示均值		
μ	类别均值 μ^c 的全局均值		
$\hat{t}_i(c)$	类别 c 的第 i 个分量的方向指示符；若 $\mu_i^c \geq \mu_i$ 则取 $+1$ ，否则取 -1		
s	控制类别相关变换尺度的正超参数		
$\hat{S}(c)$	类别相关变换尺度， $\hat{S}(c) = S_{k_c}$ ； $k_c \in \{1, \dots, m\}$ 是类别 c 按训练样本数降序排列的名次		
$\mu_{\square}^c$	类别 c 的变换均值， $\mu_{\square}^c = \hat{S}(c) \hat{t}^c$		
$\hat{v}(c)$	连接 μ^c 与 $\mu_{\square}^c$ 的类别相关变换向量		
$\hat{z}(i, c)$	使用 $\hat{v}(c)$ 变换 $\hat{e}(i, c)$ 所得的类自适应目标表示 (CATR)		
$\hat{x}_{\square}(i)$	两用网络根据 $\hat{z}(i)$ 生成的 $\hat{x}(i)$ 重构		
$\hat{z}_{\square}(i)$	训练时将 $\hat{z}(i)$ 输入两用网络和解码器所得的重构表示		
$\square(i)$	推理时把 $\hat{x}(i)$ 直接输入解码器所得的重构表示		
$\hat{y}(i, c)$	用于 TAE 经验风险分析的类别 c 的最终学习表示		
μ_c	TAE 表示的类别 c 的经验类别中心		
$z_{\square c}$	学习表示 $\hat{z}(i, c)$ 的经验类别中心		
δ	表示空间中任意两个类别中心之间的最小距离		
$r_{\max}$	表示样本到其对应类别中心的最大类内距离		
R	使用经验类别中心 $z_{\square c}$ 计算的实验风险		
R_m	MLP 使用固定类别中心 $\mu_{\square}^c$ 计算的实验风险		
R_a	MAE 使用固定类别中心 $\mu_{\square}^c$ 计算的实验风险		
R_v	CTVAE 中 $z_{\square}(i, c)$ 与 $\hat{z}(i, c)$ 平方距离均值定义的经验风险		
R_t	TAE 中 $\hat{y}(i, c)$ 与 $\hat{z}(i, c)$ 平方距离均值定义的经验风险		
R (目标中心形式)	TAE 中 $\hat{y}(i, c)$ 与 μ_c 平方距离均值定义的经验风险		

符号	定义		
μ_z	目标表示 $z^{(i,c)}$ 的类内扩散		
μ_y	学习表示 $y^{(i,c)}$ 的类内扩散		
E_c	$y^{(i,c)}$ 与 $z^{(i,c)}$ 之间的表示偏差能量		

****表 1：所提 TAE 与相关工作的比较。****

模型	数据复杂度/表现	物联网部署
SVM、DT、RF [7]; XGBoost [26]、[1]	高维、多类别问题	轻量，适合物联网 [6]、[27]
MLP [28]、1D-CNN [29]	准确率低 [6]、[8]	适合物联网 [30]
AlexNet、VGG、ResNet [11]; MLP Transformer [12]、Transformer-1DCNN [13]	可达到高准确率 [30]; 多类别时性能下降 [29]	因规模过大而困难 [14]
AE 模型 (CSAE [18]; MVAE、MAE [8])	高准确率 [11]	可部署但训练复杂
CTVAE [6]	高准确率 [6]、[8]	后验坍塌困难 [19]、[31]; 规模大时困难
SDSSL [23]、ATAS [24]、COSMOS [25]	高准确率; 多类别问题困难	物联网友好, 训练复杂度较低
所提 TAE	高准确率 [6]; 比相关模型高约 2%; 可处理多类别问题	物联网友好

B. 变换算子

图 2 和算法 1 详细示例说明了通过变换算子生成 CATR 的方法。计算整个数据集的全局均值 μ 。对于每个类别 c ，将其均值 $\mu^{(c)}$ 沿角平分线方向移离 μ ，即进一步远离原点。算法 1 中，把 $e^{(i)}$ 变换为 $z^{(i)}$ 的步骤如下：

1. 使用主成分分析 (Principal Component Analysis, PCA) 把原始数据集 X 降到潜在向量 $e^{(i)}$ 的维度。
2. 计算每个类别 c 的均值 $\mu^{(c)}$ 以及总体均值 μ 。
3. 对每个类别应用 $\mu \square^{(c)} = S^{(c)} t^{(c)}$ ，计算变换后的新均值。其中 $t^{(c)}$ 是从 $\mu^{(c)}$ 变换到 $\mu \square^{(c)}$ 的方向。令 $S^{(c)} = S_{k_c}$ ，其中 $k_c \in \{1, \dots, m\}$ 是类别 c 按训练样本数降序排列时的名次。因此，样本最多的类别 $k_c=1$ ，样本最少的类别 $k_c=m$ 。每个特征维度 i 中，若 $\mu_i^{(c)} \geq \mu_i$ (含相等情形)，则 $t_i^{(c)}=+1$ ；否则 $t_i^{(c)}=-1$ 。这种排序为训练样本较少的类别分配更大的变换尺度，从而增大其目标表示与其他类别的间隔，使解码器更好地捕捉依赖类别的平移效果。算法中也记作 $k_c \in [2, m+2]$ ， $S>0$ 为控制类别均值距离的超参数。
4. 按连接旧均值 $\mu^{(c)}$ 与新均值 $\mu \square^{(c)}$ 的向量 $v^{(c)} = V(\mu^{(c)}, \mu \square^{(c)})$ ，把类别 c 的潜在向量 $e^{(i,c)}$ 变换为 $z^{(i,c)}$ ： $z^{(i,c)} = e^{(i,c)} + V(\mu^{(c)}, \mu \square^{(c)})$ 。 $z^{(i,c)}$ 称为类别为 c 的数据样本 $x^{(i)}$ 的软标签。

与传统知识蒸馏不同，TAE 不使用单独训练的教师网络生成目标输出，而是使用编码器表示 $e^{(i,c)}$ 与由 PCA 类别统计和均值移动构造的确定性类别变换，共同生成 $z^{(i,c)} = e^{(i,c)} + v^{(c)}$ 。因此，编码器和确定性变换共同充当隐式目标生成器。随后训练解码器，从输入重构编码器生成的目标表示，使 TAE 能够从自身表示内部生成的目标中学习，而不依赖外部教师网络。我们将这一机制称为无教师自蒸馏，以强调目标表示由模型自身表示确定性生成，无需单独训练高容量教师网络或额外的教师训练阶段。

****算法 1：把潜在表示变换为可分表示以生成 CATR。****

输入：数据集 $X = \{x^{(i)}\}_{i=1}^n$ ，其中 $x^{(i)}$ 属于类别 c ；类别集合 C ； n_c 为类别 $c \in C$ 的样本数； $|C|$ 为类别数； $x^{(i,c)}$ 表示标签为 c 的 $x^{(i)}$ 。输出： $\mu^{(c)}$ 、 $\mu \square^{(c)}$ 、软标签 $z^{(i,c)}$ 。

□ 步骤 1: 对输入数据应用 PCA: $\mathbf{x}_r = \text{PCA}(\mathbf{X})$ 。

□ 步骤 2: 计算类别 c 的均值: $\mu(c) = (1/n_c) \sum_{i=1}^{n_c} \mathbf{x}_r(i, c)$, 并计算中心均值: $\mu = (1/|C|) \sum_{c=1}^{|C|} \mu(c)$ 。

□ 步骤 3: 对每个类别计算 $\mu_\square(c) = S(c) \mu_t(c)$ (原文公式按排版记为 $\mu_\square(c) = S(c) t(c)$)。

□ 步骤 4: 对 $\mathbf{X}$ 中每个 $\mathbf{x}(i, c)$ 生成软标签 $\mathbf{z}(i, c) = e(i, c) + V(\mu(c), \mu_\square(c))$ 。

图 1: 所提孪生自编码器 (TAE) 概览: (a) 第 i 个输入样本的 TAE 架构; (b) TAE 的训练与推理过程。训练时: $\mathbf{x}, c \rightarrow \text{编码器} \rightarrow \mathbf{e} \rightarrow \text{变换 } +v(c) \rightarrow \mathbf{z} \rightarrow \text{两用网络} \rightarrow \mathbf{x}_\square \rightarrow \text{解码器} \rightarrow \mathbf{z}_\square$; 推理时: $\mathbf{x} \rightarrow \text{解码器} \rightarrow \text{重构表示}$ 。

图 2: 在四类数据集上应用 TAE 变换算子的示例。图中类别均值 $\mu(1) \cdots \mu(4)$ 被移动到 $\mu_\square(1) \cdots \mu_\square(4)$, 对应方向 $t(1) \cdots t(4)$, 从而获得彼此分离的目标表示。

C. 损失函数

TAE 以监督方式训练。对于带标签 $\mathbf{Y} = \{y(i)\}_{i=1}^n$ 的数据集 $\mathbf{X} = \{\mathbf{x}(i)\}_{i=1}^n$, TAE 的损失函数包含四项:

$$\mathcal{L}_{\text{TAE}} = (1/n) \sum_{i=1}^n [(\mathbf{x}(i) - \mathbf{x}_\square(i))^2 + (\mathbf{z}(i) - \mathbf{z}_\square(i))^2 + (\mathbf{z}(i) - \mu(c))^2 + (e(i) - \mu(c))^2] \quad (2)$$

其中, $\mathbf{x}_\square(i)$ 是把输入 $\mathbf{x}(i)$ 直接送入 TAE 解码器时得到的重构表示; $\mu(c)$ 是算法 1 步骤 2 中计算的类别 c 数据样本均值。式 (2) 第一项是 $\mathbf{x}(i)$ 与 $\mathbf{x}_\square(i)$ 之间的重构误差; 第二项是 $\mathbf{z}(i)$ 与 $\mathbf{z}_\square(i)$ 之间的重构误差; 第三项用于以输入 $\mathbf{x}(i)$ 训练解码器; 第四项旨在把潜在向量 $e(i)$ 收缩到各类别均值 $\mu(c)$, 防止不同类别的潜在表示重叠。

III. TAE 的条件表示稳定性分析

本节首先推导完美表示的理论条件, 并刻画经验风险与表示质量之间的关系。随后, 在 TAE 的经验误差低于 MLP 和 MAE 等基线模型的特定条件下, 建立所提 TAE 的条件表示稳定性。

A. 表示质量与完美分离的条件

引理 1 (完美表示) 定义

$$\delta := \min_{a \neq b, a, b \in C} \|\mathbf{z}_\square(a) - \mathbf{z}_\square(b)\|, \quad (3)$$

$$r_{\max} := \max_{c \in C, 1 \leq i \leq n_c} \|\mathbf{z}(i, c) - \mathbf{z}_\square(c)\|, \quad (4)$$

$$\mathbf{z}_\square(c) := (1/n_c) \sum_{i=1}^{n_c} \mathbf{z}(i, c). \quad (5)$$

若 $r_{\max} < \delta/2$, 则对所有 $c \neq c'$, 每个表示样本 $\mathbf{z}(i, c)$ 都更接近自己的类别中心 $\mathbf{z}_\square(c)$, 而不是其他类别中心 $\mathbf{z}_\square(c')$ 。

引理 1 将 $r_{\max}$ 定义为最大类内半径, 表示任一样本距离自己类别中心的最大距离; δ 是最小类间距离, 表示最近一对类别中心之间的距离; $\mathbf{z}_\square(c)$ 是训练后类别 c 的表示数据中心。

证明。 令 $\mathbf{z}$ 为属于类别 $a \in C$ 的表示, $b \in C$ 为另一个类别。由三角不等式, 有

$$\|\mathbf{z} - \mathbf{z}_\square(b)\| \geq \|\mathbf{z}_\square(a) - \mathbf{z}_\square(b)\| - \|\mathbf{z} - \mathbf{z}_\square(a)\|. \quad (6)$$

$$\text{结合式 (3) 和 (4), 得到 } \|\mathbf{z} - \mathbf{z}_\square(b)\| \geq \delta - r_{\max}. \quad (7)$$

由式 (4) 还有 $\|\mathbf{z} - \mathbf{z}_\square(a)\| \leq r_{\max}$ 。为保证类别 a 的每个表示 $\mathbf{z}(i, a)$ 都更接近自己的中心而不是任意其他中心, 需要 $\delta - r_{\max} > r_{\max}$, 等价于 $r_{\max} < \delta/2$ 。在此条件下, 对所有 $b \neq a$ 都有 $\|\mathbf{z} - \mathbf{z}_\square(b)\| > \|\mathbf{z} - \mathbf{z}_\square(a)\|$ 。

****引理 2（经验风险与表示质量）**。**令表示模型 `f` 的经验风险为

$$R = (1/N) \sum_{(c=1)}^C \sum_{(i=1)}^{(n_c)} ||z^{\wedge}(i, c) - z^{\square}(c)||^2。 \quad (8)$$

则有：1) 较小的经验风险 `R` 表明样本 `z^{\wedge}(i, c)` 更接近各自类别中心，因此表示更紧凑且更具判别性；2) 如果 `R < \delta^2/4`，则模型 `f` 达到完美表示。

式 (8) 表明，随着 `R` 减小，各类别表示样本更接近相应类别中心，因而表示更好、更紧凑。式 (9) 表明，当 `R` 降到 ` \delta^2/4` 以下时，模型 `f` 达到完美表示，即每个类别的表示样本都比其他类别中心更接近自己的类别中心。

****证明。**** 根据式 (4)，有 `||z^{\wedge}(i, c) - z^{\square}(c)||^2 \leq r\_{\max}^2`，因此

$$R = (1/N) \sum_{(c, i)} ||z^{\wedge}(i, c) - z^{\square}(c)||^2 \leq (1/N) \sum_{(c, i)} r_{\max}^2 = r_{\max}^2。 \quad (10)$$

由引理 1，`r\_{\max} < \delta/2`，所以 `R < \delta^2/4` 成立。

B. TAE 的条件表示稳定性

为评价 MLP [36]、MAE [8]、CTVAE [6] 和 TAE 训练后的数据表示，作如下假设：

- (A0) 被比较模型的可训练组件——MLP、MAE 的编码器、CTVAE 和 TAE 的解码器——在架构上匹配，即对应层数和每层神经元数相同。它们使用相同的训练设置，包括学习率、批大小、权重初始化种子和优化算法。模型特定的超参数通过相同的训练/验证过程选择，并在评估最终经验风险前固定。
- (A1) 其余组件在训练期间固定，包括 MAE 的解码器以及 CTVAE 和 TAE 的编码器与 Hermap 模块。这些组件视为预训练模块。
- (A2) 所有模型使用相同训练数据。
- (A3) 类别特定变换算子 `v^{\wedge}(c)` 的灵活性由超参数 `s` 控制；使用训练数据选择 `s`，以保证足够的类间方差来分离不同类别的样本。
- (A4) 理论比较中，假定 MLP 与 MAE 对同一训练样本产生相同的潜在表示，即对所有 `i, c`，`m^{\wedge}(i, c) = a^{\wedge}(i, c)`。
- (A5) 与目标表示比较时，假定 MAE 产生的潜在表示与对应目标表示一致，即对所有 `i, c`，`a^{\wedge}(i, c) = z^{\wedge}(i, c)`。

我们定义直接用于提取数据表示的相应经验风险（表 III）。MLP 和 MAE 都使用算法 1 生成的码字 `μ^{\square}(c)`，而 CTVAE 使用 `μ^{\square}(c)` 从分布 `N(μ^{\square}(c), I)` 生成数据样本。`m^{\wedge}(i)` 和 `a^{\wedge}(i)` 分别表示 MLP 和 MAE 潜在空间中的数据；CTVAE 和 TAE 的表示分别是 `z^{\square}(i)` 和 `□^{\wedge}(i)`。经验风险越低，说明模型学到的表示越好，也更可能提供更好的数据表示 [37]。

****表 III：MLP [36]、MAE [8]、CTVAE [6] 和 TAE 的经验风险定义。****

模型	经验风险定义						
MLP	$R_m = (1/N) \sum_{(c=1)}^C$	C	$\sum_{(i=1)}^{(n_c)}$		$m^{\wedge}(i, c) - \mu^{\square}(c)$		□` (11)
MAE	$R_a = (1/N) \sum_{(c=1)}^C$	C	$\sum_{(i=1)}^{(n_c)}$		$a^{\wedge}(i, c) - \mu^{\square}(c)$		□` (12)
CTVAE	$R_v = (1/N) \sum_{(c=1)}^C$	C	$\sum_{(i=1)}^{(n_c)}$		$z^{\square}(i, c) - z^{\wedge}(i, c)$		□` (13)
TAE	$R_t = (1/N) \sum_{(c=1)}^C$	C	$\sum_{(i=1)}^{(n_c)}$		$\square^{\wedge}(i, c) - z^{\wedge}(i, c)$		□` (14)

****注释 1。**** 在假设 (A0) - (A2) 下，当类别中心 `μ^{\square}(c)` 按算法 1 计算时，由式 (11) 和 (12) 可知 `R\_m = R\_a`。

****证明.**** 从每个样本输出集合到类别中心的映射是确定性的，且对所有 i, c 有 $m^{\wedge}(i, c) = a^{\wedge}(i, c)$ ，因此 $\mu^{\wedge}(c)$ 对两个模型相同，即 MLP 与 MAE 相同。于是对所有 i, c ， $\|m^{\wedge}(i, c) - \mu^{\wedge}(c)\| = \|a^{\wedge}(i, c) - \mu^{\wedge}(c)\|$ ，从而 $R_m = R_a$ 。

****引理 3.**** 令式 (8) 中的 R 为使用经验类别中心 $z_{\square c}$ 计算的实验风险，其中 $z_{\square c}$ 是训练后最终学习表示的均值。令式 (11)、(12) 中的 R_m 、 R_a 为使用固定目标类别中心 $\mu^{\wedge}(c)$ 计算的实验风险，这些中心在训练前预先确定并在学习过程中保持不变。则

$$R \leq R_a \text{ 且 } R \leq R_m. \quad (15)$$

引理 3 表明，经验类别中心是最小化类内表示误差的最优固定代表。对于一组给定的学习表示，用相应的经验类别中心替代任何固定类别代表不会增加实验风险。因此， $R \leq R_a$ 和 $R \leq R_m$ 直接来自经验类别中心的最优性。

****证明.**** 式 (15) 左侧由以下不等式成立：

$$\sum_{i=1}^{n_c} \|z^{\wedge}(i, c) - z_{\square c}\| \leq \sum_{i=1}^{n_c} \|a^{\wedge}(i, c) - \mu^{\wedge}(c)\|. \quad (16)$$

在假设 (A0) - (A2) 下， $a^{\wedge}(i, c) = z^{\wedge}(i, c)$ 。计算式 (16) 的右侧：

$$\begin{aligned} \sum_i \|a^{\wedge}(i, c) - \mu^{\wedge}(c)\| &= \sum_i \|(a^{\wedge}(i, c) - z_{\square c}) + (z_{\square c} - \mu^{\wedge}(c))\| \\ &= \sum_i \|a^{\wedge}(i, c) - z_{\square c}\| + n_c \|z_{\square c} - \mu^{\wedge}(c)\| + 2(z_{\square c} - \mu^{\wedge}(c))^T \sum_i (a^{\wedge}(i, c) - z_{\square c}). \end{aligned} \quad (17)$$

$$\text{由式 (5), } \sum_i (a^{\wedge}(i, c) - z_{\square c}) = \sum_i (z^{\wedge}(i, c) - z_{\square c}) = \sum_i z^{\wedge}(i, c) - n_c z_{\square c} = 0. \quad (18)$$

因此

$$\sum_i \|a^{\wedge}(i, c) - \mu^{\wedge}(c)\| = \sum_i \|a^{\wedge}(i, c) - z_{\square c}\| + n_c \|z_{\square c} - \mu^{\wedge}(c)\| \geq \sum_i \|z^{\wedge}(i, c) - z_{\square c}\|. \quad (19)$$

注释 1 给出式 (15) 右侧的结论。事实上，训练前并不知道 $z_{\square c}$ 的精确值。但如果假定 $z_{\square c}$ 在训练前已确定，那么远离相应中心的数据样本对实验风险的贡献更大，接近中心的样本贡献更小。因此，TAE 旨在把数据投影到为每个数据样本自适应计算的 CATR，而不是依赖固定类别中心；这可能导致更低实验风险。

****引理 4 (TAE 的条件表示稳定性).**** 令 TAE 的经验风险以目标表示为固定类别中心：

$$R = (1/N) \sum_{c=1}^C \sum_{i=1}^{n_c} \|y^{\wedge}(i, c) - \mu_c\|, \text{ 其中 } \mu_c = (1/n_c) \sum_i y^{\wedge}(i, c). \quad (20)$$

$$\text{对固定类别 } c, \text{ 定义 } z_i := z^{\wedge}(i, c), y_i := y^{\wedge}(i, c), \epsilon_i := y_i - z_i, \mu_c := \mu_c - z_{\square c}. \quad (21)$$

令类内目标表示扩散、类内学习表示扩散和表示偏差能量分别为

$$S_z := \sum_i \|z_i - z_{\square c}\|, S_y := \sum_i \|y_i - \mu_c\|, E_c := \sum_i \|\epsilon_i\|. \quad (22)$$

如果学习表示与目标表示之间的偏差能量满足

$$E_c \leq (\sqrt{2}-1) S_z, \quad (23)$$

则有表示稳定性关系

$$R_t \leq R. \quad (24)$$

引理 4 建立了 TAE 条件表示稳定性的充分条件。具体而言，当学习表示相对目标表示的偏差能量相对于目标表示的类内扩散足够小时，表示偏差受学习表示类内扩散的约束；在此条件下， $R_t \leq R$ 随稳定性条件自然成立。

****证明.**** 根据式 (21)，

$$y_i - \mu_c = (y_i + z_i) - (\mu_c + z_i) = (y_i - \mu_c) + (z_i - z_i). \quad (25)$$

由式 (22),

$$S_y = \sum_i ||y_i - \mu_c||^2 + \sum_i ||z_i - z_i||^2 + 2 \sum_i (y_i - \mu_c, z_i - z_i). \quad (26)$$

第一项为

$$A := \sum_i ||y_i - \mu_c||^2 = \sum_i y_i^2 - 2 \sum_i y_i \mu_c + n_c \mu_c^2. \quad (27)$$

$$\text{由于 } \mu_c = (1/n_c) \sum_i y_i, \text{ 有 } \sum_i y_i \mu_c = \mu_c \sum_i y_i = \mu_c (n_c \mu_c) = n_c \mu_c^2. \quad (28)$$

$$\text{结合式 (22)、(27), } A = \sum_i y_i^2 - n_c \mu_c^2 = S_t - n_c \mu_c^2. \quad (29)$$

处理式 (26) 第三项:

$$B := \sum_i (y_i - \mu_c, z_i - z_i) = \sum_i (y_i, z_i - z_i) - \mu_c \sum_i (z_i - z_i). \quad (30)$$

$$\text{根据式 (18), } \sum_i (z_i - z_i) = 0, \text{ 所以第二项为零, 且 } B = \sum_i (y_i, z_i - z_i). \quad (31 - 32)$$

合并式 (29)、(32) 和 (22), 可得

$$S_y = S_t - n_c \mu_c^2 + S_z + 2B, \quad \Delta := S_y - S_t = S_z + 2B - n_c \mu_c^2. \quad (33 - 34)$$

$$\text{由柯西 - 施瓦茨不等式, } |B| \leq \sqrt{(E_c S_z)}, \text{ 故 } B \geq -\sqrt{(E_c S_z)}. \quad (35 - 37)$$

$$\text{又由 } -n_c \mu_c^2 = (1/n_c) (\sum_i y_i)^2 \leq \sum_i y_i^2 = E_c, \text{ 故 } -n_c \mu_c^2 \geq -E_c. \quad (38 - 39)$$

当 $S_z \geq 0$ 时,

$$\Delta \geq S_z - 2\sqrt{(E_c S_z)} - E_c = S_z(1 - 2\sqrt{(E_c/S_z)} - E_c/S_z). \quad (40)$$

$$\text{令 } t := \sqrt{(E_c/S_z)} \geq 0. \text{ 式 (24) 在以下条件下成立: } f(t) := 1 - 2t - t^2 \geq 0. \quad (41)$$

解方程 $t^2 + 2t - 1 = 0$, 得到 $t = -1 \pm \sqrt{2}$. 由于 $t \geq 0$, 所以 $t \in [0, -1 + \sqrt{2}]$, 即 $E_c \leq (-1 + \sqrt{2}) S_z$, 证毕。

C. TAE 的训练/推理复杂度

假设 TAE、CTVAE [6] 和 MAE [8] 编码器隐藏层的神经元数量相同, 记为 $\{l_{1d}, l_{2d}, \dots, l_{Td}\}$, 其中 d 为输入维度, T 为编码器隐藏层数。这里 l_{id} 必须为整数, 且 $0 < l_{id} < 1$ 。TAE 编码器训练复杂度为 $O(2NTd)$ 。算法 1 步骤 1 中 PCA 的复杂度为 $O(Nd^2 + d^3)$ [38]。由于 TAE 的对称性, 编码器、两用网络和解码器训练复杂度相同。因此, TAE 训练复杂度为 $O(6NTd + Nd^2 + d^3 + 6Nd + 2Cd)$, 整体训练复杂度也是该量级。与 CTVAE [6] 和 MAE [8] 一样, TAE 和 CTVAE 都只使用解码器提取表示, 类似于 MAE 中使用编码器提取表示。因此三个模型测试复杂度相同: $O(N_Td)$ (见表 IV)。这说明推理时 TAE 只依赖解码器, 适合轻量级物联网设备。

****表 IV: TAE、MAE [8] 和 CTVAE [6] 的计算复杂度比较。****

阶段/模型	复杂度
训练 MAE	$O(4NTd + 2Nd)$ (42)
训练 CTVAE	$O(2NTd + 4LNTd + Nd^2 + d^3 + 4Nd + 3Cd)$ (43)
训练 TAE	$O(6NTd + Nd^2 + d^3 + 6Nd + 2Cd)$ (44)
测试 TAE、MAE、CTVAE	$O(N_Td)$ (45)

IV. 实验设置

A. 数据集

我们使用广泛的网络安全数据集评价 TAE 的有效性，包括物联网僵尸网络攻击数据集、网络 IDS 数据集、云 DDoS 攻击数据集和恶意软件数据集。各数据集的训练、验证和测试样本数见表 V；类别数、特征数和数据集简称（ID）也列于该表。

物联网僵尸网络数据集 [4] 包括 7 个不同数据集，包含 Gafgyt 和 Mirai 两类攻击。我们在这些多分类数据集上进行两种场景实验。第一种场景包含正常流量和 5 种 Gafgyt 攻击，构成 6 类分类问题；第二种场景包含正常流量、5 种 Mirai 攻击和 5 种 Gafgyt 攻击，构成 11 类问题。数据集名称用数据集名和攻击类型缩写，例如 EcoG 表示 Ecobee 数据集上的 Gafgyt 攻击，EcoMG 表示同时包含 Mirai 和 Gafgyt 的 Ecobee 数据集。

IDS 数据集包括 NSLKDD (NSL) [32] 和 UNSW-NB15 (UNSW) [33]。NSL 数据包含良性流量和 4 类攻击，即 DoS、R2L、Probe 和 U2L。其中 R2L 与 U2L 是两种复杂而少见、很难被机器学习算法检测的攻击 [39]。UNSW 数据集包含良性流量和 9 类攻击。NSL 与 UNSW 都是不平衡数据集，因为 NSL 中 R2L、U2R 的样本数，以及 UNSW 中 Worms、Backdoor、Shellcode 的样本数显著少于其他类别。

恶意软件数据集包含物联网系统上的 20 个恶意软件家族 [34]。其中有 3 个二分类恶意软件数据集 Mal1、Mal2 和 Mal3，每个样本有 32 个特征。训练集包含良性样本和典型恶意软件家族（如 DDoS 和 Part-of-Horizontal-Port-Scan），而测试集包含良性样本及更多复杂的恶意软件类别（如 C&C-attack、Okiru、C&C-heartbeat、C&C-Mirai 和 C&C-PortScan）。换言之，测试集的一些恶意软件在训练集不可见，因此 ML 模型很难检测这些未知恶意软件。

云 IDS 数据集是云环境中的 DDoS 攻击数据集。Kumar 等人 [35] 通过模拟云环境并使用开源平台启动 15 台正常虚拟机、1 台目标虚拟机和 3 台恶意虚拟机发布了这些数据。提取的数据集包含 24 个基于时间的流量特征，并按 70:30 划分训练集和测试集。

为评价训练类别数增加时 TAE 的类别分离性能，我们生成了人工数据集。使用库创建数据集，参数包括类别数 `n\_classes`、样本维度 `n\_feature` 和每类样本数 `n\_points\_per\_class` [40]。为保证可复现性，随机种子设为 2021；数据按 70:30 划分训练集和测试集。具体地，创建 10 个数据集，`n\_classes={50, 100, 150, 200, 250, 300, 350, 400, 450, 500}`，所有数据集 `n\_feature=100`、`n\_points\_per\_class=1000`；此外创建 8 个小规模数据集，`n\_classes={5, 10, 15, 20, 25, 30, 35, 40}`，`n\_feature=100`、`n\_points\_per\_class=100`。

表 V：数据集信息。

数据集	ID	训练	验证	测试	类别数	特征数
DanG [4]	IoT1	179434	76901	109863	6	115
EcoG [4]	IoT2	158631	67986	97126	6	115
PhiG [4]	IoT3	239099	102472	146392	6	115
737G [4]	IoT4	192200	82372	117678	11	115
838G [4]	IoT5	199698	85586	122270	10	42
EcoMG [4]	IoT6	409574	175533	250769	2	32
838MG [4]	IoT7	410071	175746	251074	7	24
NSLKDD [32]	NSL	88181	37792	22544	7	24
UNSW-NB15 [33]	UNSW	57632	24700	175341	10	42
IoT Malware 1 [34]	Mal1	57544	14387	8888	2	32
IoT Malware 2 [34]	Mal2	6498	1625	2603	2	32
IoT Malware 3 [34]	Mal3	10183	2546	53624	2	32

数据集	ID	训练	验证	测试	类别数	特征数
Cloud IDS [35]	Cloud	1239381	517915	887113	—	—

原文表格的 PDF 文本提取还保留了紧随物联网数据集行的类别/特征续行：`6/115`、`6/115`、`11/115`、`5/41`、`2/32`、`2/32`；这些续行在原版表格中用于不同攻击场景的对应条目，因抽取版列对齐丢失，无法可靠映射到单独的数据集，现按原顺序保留。

B. 超参数设置

测试的表示学习方法包括 TAE、MVAE、MAE [8] 和 CSAEC [18], [41]。此外，还将 TAE 与常用机器学习模型比较，包括多层感知机（Multi-Layer Perceptron, MLP）[30], [28]、支持向量机（SVM）、决策

树（DT）、随机森林（RF）、一维卷积神经网络（1D-CNN）[29]、MLP 和先进的 XGBoost（Xgb）[26], [1]。

实验使用 TensorFlow 和 Scikit-learn 两个框架实现。所有数据集均使用 Min-Max 归一化。我们使用网格搜索调节每种 ML 模型的超参数（表 VI）。对于表示学习方法，提取最终表示作为决策树（DT）模型的输入，并报告 DT 的性能。对于 SDSSL [23]，遵循原实现，仅应用 k 近邻（KNN）分类器。

对于 MAE、MVAE 和 TAE 三种神经网络模型，其子网络（编码器、两用网络和解码器）均只使用一个带 ReLU 激活的隐藏层。使用 ADAM 优化算法 [42] 训练，学习率 $\alpha=10^{-4}$ ，训练 5000 个 epoch，批大小为 100。使用验证集（训练集的 30%）进行提前停止：如果连续 10 个 epoch 的损失函数差异低于阈值 $\Delta=1$ ，就停止训练。文献 [8] 仅在二分类数据集上研究 MAE 和 MVAE；本文将其扩展到多分类问题，把 $\mu_j(c)$ 的值从 2 扩展到 $n+2$ ，其中 n 为类别数。

对于 CSAE，采用文献 [41] 中使用 1D 卷积的相同架构。以无监督方式训练 CSAE 后，在编码器上添加 Softmax 层，再以监督方式继续训练。监督训练后移除 Softmax 层，所得编码器称为 CSAEC，用于提取下游评估的学习表示。CSAEC 表示也使用相同的 DT 分类器评估。对于 TAE，还调节变换算子尺度 s 和潜在空间维度 d_z 两个超参数。AE 模型编码器神经元数设为 $\{d, 0.9d, 0.8d, 0.7d, d_z\}$ ，其中 d 为输入维度， $d_z=[\sqrt{d}]+1$ 为潜在空间维度 [8], [6]；解码器结构与编码器对称。

对于基于 Transformer 的模型（MLP [12] 和 1DCNN [13]），调节注意力头数。对于自蒸馏方法，SDSSL [23] 依据潜在空间维度以及生成不同视图的策略调节，包括噪声标准差和移位操作。对于 ATAS [24] 和 COSMOS [25]，优化损失分量之间的权衡系数。由于 SDSSL、ATAS 和 COSMOS 原本面向图像领域，我们将其适配到物联网网络安全数据集，使用结合注意力机制的 1DCNN 主干和 4 个注意力头。

为设置固定码字实验 [20]，生成长度等于潜在空间维度 d_z 的码字。 d_z 从 $\{d_z, 1.5d_z, 2d_z, 3d_z\}$ 中调节，其中 $d_z=[\sqrt{d}]+1$ 。对于 MLP，不使用 Softmax 层，而是使用码字把数据投影到潜在空间。传统方法使用独热编码向量的 Softmax 层，其大小等于类别数；MAE 使用瓶颈层作为潜在空间 [8]。

表 VI：超参数网格搜索设置。

方法	设置
KNN	<code>`neighbor={1, 2, 5, 10, 15, 35, 50}`</code>
SVM	<code>LinearSVC: `C={0.1, 0.2, 0.5, 1.0, 5.0, 10.0}`; SVC: `decision_function_shape=ovo`</code>
DT	<code>`max_depth={5, 10, 20, 50, 100}`</code>
RF	<code>`n_estimators={5, 10, 20, 50, 100, 150}`</code>
Xgb [26]、[1]	<code>`min_child_weight={5, 10}`, `gamma={0.5, 1.5}`, `subsample={1.0, 0.9}`</code>
CSAEC [18]	1D-CNN, 两个 Conv1D, kernel size=3
MAE [8]	<code>`D_z={d_z, 1.5d_z, 2d_z, 3d_z}`</code>
MVAE [8]	<code>`D_z={d_z, 1.5d_z, 2d_z, 3d_z}`</code>
CTVAE [6]	<code>`D_z={d_z, 1.5d_z, 2d_z, 3d_z}`; `S={1, 5, 10}`</code>

方法	设置
SDSSL [23]	`D_z={d_z, 2d_z}`; `std={0.1, 0.05}`; `shift={1, 5}`
ATAS [24]	`D_z={d_z, 2d_z}`; ` $\lambda_1={0.1, 0.5, 1}$ `; ` $\lambda_2={0.1, 0.5, 1}$ `
COSMOS [25]	`D_z={2d_z}`; ` $\lambda_1={0.25, 0.5, 1}$ `; ` $\lambda_2={0.25, 0.5, 1}$ `
Transformer (MLP [12]、1DCNN [13])	`nhead={2, 3, 4}`
TAE	`D_z={d_z, 1.5d_z, 2d_z, 3d_z}`; `S={1, 5, 10, 20}`

对于 KD，我们考虑两种教师架构：DeepMLP 和 ResNet。为公平比较，使用紧凑 MLP 作为客户端模型。DeepMLP 教师由 128、128、64 个隐藏单元的三个全连接层、两个残差全连接块和 64 维嵌入组成。ResNet 教师采用 128 维全连接主干、12 个残差块和 128 维嵌入。客户端 MLP 使用 64-64-32 主干、两个残差块和 32 维嵌入，并使用硬标签损失与温度缩放软标签损失的加权组合进行 KD [22]。由于 IoT1 - IoT5 具有相同的类别定义，我们在 IoT1 上训练 KD 教师模型，随后在 IoT2、IoT3、IoT4 和 IoT5 上训练并评估紧凑学生模型。

V. 性能分析

A. 检测模型准确率

表 VII 比较了 TAE 与基于 Transformer 的模型（MLP、1DCNN）、自蒸馏方法（SDSSL、ATAS、COSMOS）以及其他表示学习方法（CSAEC、MVAE、MAE、CTVAE）在 13 个物联网数据集上的表现。TAE 始终取得最高准确率和 F1 分数，平均准确率为 0.901，超过 MLP（0.762）、1DCNN（0.734）、SDSSL（0.855）、ATAS（0.848）、COSMOS（0.831）、CSAEC（0.872）、MVAE（0.708）、MAE（0.871）和 CTVAE（0.883）。TAE 的优势来自确定性的类自适应表示，它比面向图像的自蒸馏方法和基于码字的表示学习方法更适合物联网数据的异构特征结构。特别是，确定性变换避免了 MVAE 和 CTVAE 等 VAE 方法遇到的后验坍缩。

****表 VII：TAE 与 Transformer、自蒸馏和其他表示学习方法的性能比较。****（数值依次为 IoT1、IoT2、IoT3、IoT4、IoT5、IoT6、IoT7、NSL、UNSW、Cloud、Mal-1、Mal-2、Mal-3、平均值。）

指标	方法	数值
Accuracy	Transformer (MLP)	0.672, 0.626, 0.758, 0.659, 0.725, 0.850, 0.860, 0.862, 0.736, 0.976, 0.512, 0.720, 0.955, 0.762
	Transformer (1DCNN)	0.618, 0.615, 0.755, 0.646, 0.667, 0.813, 0.844, 0.861, 0.748, 0.887, 0.414, 0.719, 0.955, 0.734
	SDSSL	0.938, 0.915, 0.958, 0.945, 0.939, 0.716, 0.857, 0.832, 0.671, 0.973, 0.513, 0.901, 0.955, 0.855
	ATAS	0.924, 0.918, 0.941, 0.913, 0.933, 0.746, 0.878, 0.819, 0.647, 0.943, 0.512, 0.895, 0.955, 0.848
	COSMOS	0.928, 0.905, 0.948, 0.936, 0.921, 0.722, 0.880, 0.844, 0.667, 0.963, 0.415, 0.720, 0.955, 0.831
	CSAEC	0.923, 0.914, 0.941, 0.933, 0.928, 0.882, 0.929, 0.843, 0.734, 0.980, 0.512, 0.889, 0.920, 0.872
	MVAE	0.688, 0.608, 0.751, 0.654, 0.713, 0.536, 0.747, 0.829, 0.681, 0.867, 0.514, 0.687, 0.929, 0.708

指标	方法	数值
	MAE	0.925, 0.913, 0.950, 0.935, 0.931, 0.876, 0.933, 0.842, 0.704, 0.960, 0.512, 0.917, 0.921, 0.871
	CTVAE	0.933, 0.930, 0.965, 0.939, 0.948, 0.931, 0.934, 0.863, 0.741, 0.980, 0.513, 0.877, 0.921, 0.883
	TAE	0.931, 0.933, 0.985, 0.949, 0.993, 0.959, 0.975, 0.873, 0.747, 0.987, 0.517, 0.914, 0.955, 0.901
F-score	Transformer (MLP)	0.599, 0.624, 0.616, 0.597, 0.650, 0.778, 0.798, 0.645, 0.436, 0.843, 0.462, 0.634, 0.902, 0.660
	Transformer (1DCNN)	0.562, 0.603, 0.598, 0.576, 0.574, 0.755, 0.776, 0.620, 0.449, 0.699, 0.299, 0.633, 0.902, 0.619
	SDSSL	0.929, 0.900, 0.951, 0.938, 0.925, 0.706, 0.842, 0.793, 0.633, 0.973, 0.433, 0.899, 0.957, 0.837
	ATAS	0.904, 0.902, 0.919, 0.891, 0.916, 0.726, 0.870, 0.781, 0.612, 0.943, 0.432, 0.892, 0.957, 0.827
	COSMOS	0.909, 0.878, 0.938, 0.921, 0.903, 0.706, 0.862, 0.803, 0.637, 0.962, 0.250, 0.672, 0.957, 0.800
	CSAEC	0.895, 0.887, 0.919, 0.915, 0.899, 0.886, 0.923, 0.798, 0.692, 0.980, 0.432, 0.887, 0.928, 0.849
	MVAE	0.642, 0.528, 0.666, 0.536, 0.702, 0.617, 0.713, 0.779, 0.623, 0.819, 0.435, 0.683, 0.935, 0.668
	MAE	0.900, 0.885, 0.937, 0.918, 0.908, 0.867, 0.934, 0.804, 0.659, 0.960, 0.432, 0.917, 0.929, 0.850
	CTVAE	0.915, 0.916, 0.960, 0.931, 0.937, 0.927, 0.923, 0.826, 0.673, 0.979, 0.433, 0.873, 0.929, 0.863
	TAE	0.916, 0.922, 0.985, 0.944, 0.993, 0.949, 0.970, 0.844, 0.695, 0.987, 0.439, 0.912, 0.958, 0.886

表 VIII 将 TAE 与 SVM、DT、RF、1D-CNN、MLP 和 Xgb 六种流行机器学习模型在各数据集上的表现进行比较。两个结果值得注意。第一，除 Xgb 外，TAE 一贯优于其他模型。例如在 IoT1 上，TAE 准确率为 0.931，而 SVM、DT、RF、1D-CNN 和 MLP 分别为 0.670、0.672、0.672、0.635 和 0.706。这说明测试问题中的原始数据表示给传统机器学习方法带来挑战；但 TAE 将原始表示变换为更可分的形式，再通过重构机制重构，便使数据更适合机器学习模型。第二，性能最接近 TAE 的模型是 Xgb；尽管如此，TAE 仍然超过 Xgb，显示出其在网络攻击检测方面更强的能力。

****表 VIII：TAE 与流行机器学习模型的性能比较。*** 下列每行数值依次为 IoT1、IoT2、IoT3、IoT4、IoT5、IoT6、IoT7、NSL、UNSW、Cloud、Mal-1、Mal-2、Mal-3、平均值。

指标	方法	数值
Accuracy	SVM	0.923, 0.910, 0.941, 0.921, 0.928, 0.941, 0.959, 0.872, 0.762, 0.985, 0.419, 0.607, 0.921, 0.736
	DT	0.670, 0.612, 0.751, 0.655, 0.708, 0.837, 0.856, 0.844, 0.672, 0.890, 0.409, 0.720, 0.939, 0.742
	RF	0.672, 0.654, 0.753, 0.656, 0.740, 0.844, 0.867, 0.866, 0.743, 0.977, 0.414, 0.544, 0.918, 0.757
	1D-CNN	0.672, 0.613, 0.752, 0.656, 0.709, 0.850, 0.858, 0.871, 0.757, 0.983, 0.416, 0.777, 0.921, 0.739
	MLP	0.635, 0.613, 0.752, 0.654, 0.709, 0.820, 0.846, 0.839, 0.703, 0.980, 0.474, 0.674, 0.911, 0.765
	TAE-DT	0.706, 0.739, 0.810, 0.733, 0.780, 0.724, 0.856, 0.861, 0.722, 0.926, 0.414, 0.719, 0.954, 0.901
	TAE	0.931, 0.933, 0.985, 0.949, 0.993, 0.959, 0.975, 0.873, 0.747, 0.987, 0.517, 0.914, 0.955
Accuracy	Xgb	原文表格提取仅显示平均值 0.853
F1-score	Xgb	原文表格提取仅显示平均值 0.823
F1-score	SVM	0.894, 0.879, 0.918, 0.891, 0.900, 0.929, 0.945, 0.830, 0.733, 0.985, 0.259, 0.608, 0.929, 0.655
	DT	0.553, 0.475, 0.662, 0.535, 0.603, 0.784, 0.805, 0.794, 0.606, 0.842, 0.238, 0.670, 0.944, 0.679
	RF	0.557, 0.547, 0.665, 0.536, 0.658, 0.799, 0.824, 0.828, 0.720, 0.977, 0.250, 0.545, 0.926, 0.685
	1D-CNN	0.557, 0.477, 0.664, 0.536, 0.604, 0.797, 0.807, 0.827, 0.727, 0.982, 0.252, 0.751, 0.929, 0.669
	MLP	0.515, 0.477, 0.663, 0.534, 0.605, 0.768, 0.796, 0.788, 0.646, 0.979, 0.366, 0.635, 0.920, 0.698
	TAE-DT	0.605, 0.651, 0.744, 0.645, 0.703, 0.635, 0.815, 0.822, 0.671, 0.913, 0.248, 0.670, 0.956, 0.886
	TAE	0.916, 0.922, 0.985, 0.944, 0.993, 0.949, 0.970, 0.844, 0.695, 0.987, 0.439, 0.912, 0.958

讨论

总体而言，以上结果显示，所提 TAE 在广泛网络安全问题上优于其他表示学习和机器学习算法。TAE 以监督方式训练，性能通常优于 MAE 和 CSAEC 等先进表示模型；与使用原始数据集的 SVM、DT、RF、1D-CNN 和 MLP 等知名机器学习模型相比，TAE 也显示出优势。TAE 的结果几乎都高于先进的集成学习方法 Xgb。

B. 复杂攻击检测

NSL 数据集中的 R2L 和 U2R 是会挑战传统机器学习模型的复杂攻击 [43]。U2R 攻击利用系统漏洞获得超级用户或 root 权限，引起难以与正常活动区分的细微系统行为变化。R2L 攻击发生在攻击者试图未经授权访问远程系统时，通常利用漏洞或暴力破解登录凭据；它们往往产生很少网络流量，因此难以检测。测试方法在 NSL 上的混淆矩阵见表 IX，表明 TAE 比 MAE 和 Xgb 更擅长检测攻击。具体而言，TAE 在 37 个 U2R 攻击样本中检测出 10 个，而 MAE 和 Xgb 分别只检测出 1 个和 4 个；对 R2L 攻击，TAE 在 2199 个样本中正确检测 475 个，而 MAE 和 Xgb 只检测出 79 个和 135 个。

表 IX：NSL 数据集上 TAE、MAE 和 Xgb 的混淆矩阵。

方法/真实类别	Normal	DoS	U2R	R2L	Probe
TAE-Normal	9475	56	5	23	152
TAE-DoS	150	5557	0	0	34
TAE-U2R	23	2	10	0	2
TAE-R2L	1689	7	22	475	6
TAE-Probe	223	2	0	0	881
MAE-Normal	9441	93	4	14	159
MAE-DoS	301	5333	1	11	95
MAE-U2R	25	71	2	2	—
MAE-R2L	1986	109	3	79	22
MAE-Probe	253	7	1	0	845
Xgb-Normal	9428	81	1	0	201
Xgb-DoS	12	5716	0	0	13
Xgb-U2R	31	0	42	0	0
Xgb-R2L	2037	0	1	135	26
Xgb-Probe	1	0	0	0	1105

Ping-of-death、Slowloris 和 TCP-land 是 Cloud 数据集上的三种流行网络中断攻击 [35]。Ping-of-death 利用 ICMP（Internet Control Message Protocol，互联网控制消息协议）等网络协议的漏洞，而 ICMP 对诊断和连接检查等服务至关重要；区分合法与恶意 ICMP 数据包很有挑战。TCP-land 和 Slowloris 攻击向目标发送少量数据包，通常每秒仅几个，容易与合法流量混合，因而更难检测异常。表 X 的 Cloud 混淆矩阵突出显示了 Ping-of-death、Slowloris 和 Tcp-land 攻击的结果。TAE 在这些攻击上超过 MAE。例如，TAE 正确识别 Slowloris 的 145 个样本中的 138 个，而 MAE 只识别 117 个；其余两种攻击也有类似结果。TAE 与 Xgb 大多相当，但在 Slowloris 上 TAE 略好。

表 X：Cloud 数据集上 TAE、MAE 和 Xgb 的混淆矩阵。

方法/类别	I1 正常	I2 DNS-flood	I3 Ping-of-death	I4 Slowloris	I5 Tcp-land	I6 TCP-syn-flood	I7 Udp-flood
TAE I1	1151	0	0	5	0	0	0
TAE I2	0	6	0	0	0	0	5
TAE I3	0	0	18	0	0	0	0
TAE I4	7	0	0	138	0	0	0
TAE I5	0	0	0	0	11	0	0
TAE I6	0	0	0	0	0	19	0
TAE I7	0	1	0	0	0	0	13
MAE I1	1144	0	0	12	0	0	0
MAE I2	0	5	0	0	1	1	4

方法/类别	11 正常	12 DNS-flood	13 Ping-of-death	14 Slowloris	15 Tcp-land	16 TCP-syn-flood	17 Udp-flood
MAE 13	0	1	12	0	2	3	0
MAE 14	28	0	0	117	0	0	0
MAE 15	0	0	0	0	8	2	1
MAE 16	0	1	1	0	3	13	1
MAE 17	0	3	0	0	0	2	9
Xgb 11	1153	0	0	3	0	0	0
Xgb 12	0	6	0	0	0	0	5
Xgb 13	0	0	18	0	0	0	0
Xgb 14	9	0	0	136	0	0	0
Xgb 15	0	0	0	0	11	0	0
Xgb 16	0	0	0	0	0	19	0
Xgb 17	0	3	0	0	0	0	11

最后一组实验在 Ma13 数据集上比较 TAE、MAE 和 Xgb。Ma13 训练集由正常流量和一种攻击（DDoS）组成，而测试集包含 C&C-Heart-Beat-Attack、C&C-Heart-Beat-File-Download、C&C-Part-Of-A-Horizontal-Port-Scan、Okiru 和 Part-Of-A-Horizontal-Port-Scan-Attack 等未知攻击（表 XI）。TAE 在攻击检测方面超过 MAE 和 Xgb，正确识别 47,694 个攻击样本中的 45,635 个；MAE 和 Xgb 分别只识别 43,681 和 43,708 个。这突出了 TAE 检测恶意软件数据集中未知攻击的能力。

表 XI：Ma13 数据集上 TAE、MAE 和 Xgb 的混淆矩阵。

方法/真实类别	Normal	Attacks
TAE-Normal	5586	344
TAE-Attacks	2059	45635
MAE-Normal	5725	205
MAE-Attacks	4013	43681
Xgb-Normal	5677	253
Xgb-Attacks	3986	43708

C. TAE 的 CATR 与 RL 码字比较

我们比较使用 TAE 的 CATR 和码字（即 MLP 与 MAE）的表示学习模型结果。测试码字包括独热编码、Hadamard [20]，[21]、MAE 的码字，以及 TAE 不同类别数据样本的均值（TAE 的均值），如算法 1 所述。码字在训练前只计算一次，而在 TAE 每个 epoch 中 CATR 会针对每个数据样本更新。所有表示模型均使用决策树（DT）测试。

如表 XII 所示，使用 TAE CATR 的表示学习模型所得准确率和 F1 分数超过使用独热编码、Hadamard、MAE 码字和 TAE 均值的模型。此外，Hadamard 码字结果优于独热编码；TAE 均值码字又优于独热、Hadamard 和 MAE 码字。例如，在 7 个物联网数据集上，TAE CATR 的平均准确率为 0.961；使用 MAE 码字、独热编码、Hadamard 和 TAE 均值的 MAE 表示准确率分别为 0.923、0.897、0.935 和 0.942。有趣的是，使用固定码字的表示模型在准确率和 F1 分数方面排名第二，这是因为 TAE 均值由输入数据生成，有助于分离不同类别样本。这解释了 TAE 相对于使用固定码字的其他表示模型的优越性。

表 XII：TAE 的 CATR 与表示学习模型码字的性能比较。（各行数值依次为 IoT1 - IoT7、平均值。）

指标/模型	码字	数值
Accuracy / MLP	One-hot	0.923, 0.925, 0.957, 0.953, 0.937, 0.892, 0.922, 0.930
	Hadamard	0.939, 0.919, 0.955, 0.945, 0.950, 0.930, 0.938, 0.939
	TAE' s means	0.923, 0.914, 0.971, 0.925, 0.949, 0.949, 0.972, 0.943
Accuracy / MAE	MAE' s codeword	0.925, 0.913, 0.950, 0.935, 0.931, 0.876, 0.933, 0.923
	One-hot	0.923, 0.910, 0.755, 0.921, 0.932, 0.892, 0.946, 0.897
	Hadamard	0.923, 0.916, 0.945, 0.930, 0.931, 0.940, 0.962, 0.935
	TAE' s means	0.923, 0.917, 0.980, 0.940, 0.944, 0.928, 0.964, 0.942
Accuracy / TAE	CATR	0.931, 0.933, 0.985, 0.949, 0.993, 0.959, 0.975, 0.961
F1-score / MLP	One-hot	0.896, 0.907, 0.948, 0.947, 0.918, 0.882, 0.914, 0.916
F1-score / MAE	Hadamard	0.925, 0.897, 0.945, 0.935, 0.941, 0.921, 0.924, 0.927
F1-score / TAE	TAE' s means	0.896, 0.888, 0.968, 0.899, 0.938, 0.940, 0.972, 0.929
	MAE' s codeword	0.900, 0.885, 0.937, 0.918, 0.908, 0.867, 0.934, 0.907
	One-hot	0.896, 0.879, 0.670, 0.892, 0.908, 0.879, 0.938, 0.866
	Hadamard	0.895, 0.892, 0.925, 0.909, 0.906, 0.928, 0.949, 0.915
	TAE' s means	0.895, 0.893, 0.979, 0.927, 0.932, 0.918, 0.959, 0.929
	CATR	0.916, 0.922, 0.985, 0.944, 0.993, 0.949, 0.970, 0.954

D. 类别数增加时的可扩展性

我们评估训练集类别数增加时 TAE 的性能。表 XIII 给出了决策树 (DT) 使用原始数据集、MAE、CTVAE 和 TAE 数据表示所得准确率。总体而言, TAE 表示 (TAE-DT) 在 10 个人工数据集上显著高于原始数据 (DT)、MAE-DT 和 CTVAE-DT。例如, TAE-DT 的平均准确率为 0.923, 明显高于 DT 的 0.773、MAE-DT 的 0.369 和 CTVAE-DT 的 0.903。MAE-DT 的准确率最低, 因为 MAE 难以处理训练集类别数增多的问题。

****表 XIII: 训练集类别数增加时, DT 使用原始数据及 MAE、CTVAE、TAE 表示的准确率。****

类别数	50	100	150	200	250	300	350	400	450	500	平均
DT	0.896	0.846	0.811	0.787	0.770	0.756	0.735	0.726	0.706	0.698	0.773
MAE	0.725	0.636	0.592	0.503	0.407	0.258	0.165	0.140	0.142	0.119	0.369
CTVAE	0.987	0.988	0.963	0.938	0.909	0.888	0.886	0.839	0.825	0.806	0.903
TAE	0.998	0.991	0.977	0.948	0.912	0.948	0.901	0.874	0.860	0.826	0.923

我们还在小规模人工数据集上评价 TAE。表 XIV 显示，使用 TAE 表示的 DT（TAE-DT）准确率显著高于 MAE-DT、CTVAE-DT 和原始数据 DT。例如，DT、MAE-DT、CTVAE-DT 和 TAE-DT 的平均准确率分别为 0.855、0.632、0.965 和 0.991。随着训练集类别数增加，原始数据上的 DT 准确率下降；MAE-DT 也同时在类别数增加时报告较低准确率。

表 XIV：小规模人工数据集上 DT 使用原始数据及 MAE、CTVAE、TAE 表示的准确率。

类别数	5	10	15	20	25	30	35	40	平均
DT	0.953	0.903	0.862	0.843	0.845	0.844	0.806	0.781	0.855
MAE	0.967	0.803	0.642	0.530	0.524	0.477	0.567	0.548	0.632
CTVAE	1.000	0.947	0.980	0.953	0.975	0.960	0.948	0.956	0.965
TAE	1.000	1.000	1.000	0.987	0.991	0.984	0.987	0.980	0.991

E. 与知识蒸馏的比较

表 XVI 比较了所提 TAE 与使用 DeepMLP 和 ResNet 教师的 KD。TAE 的平均准确率和 F-score 始终高于两种 KD 变体：TAE 分别为 0.965 和 0.961，DeepMLP-KD 为 0.942 和 0.934，ResNet-KD 为 0.935 和 0.928。TAE 在 IoT2、IoT3 和 IoT5 上也达到最佳性能，显示出相对教师式 KD 的有效性。

表 XVI：TAE 与 DeepMLP、ResNet 教师 KD 的性能比较。

指标	方法	IoT2	IoT3	IoT4	IoT5	平均
Accuracy	DeepMLP-KD	0.906	0.955	0.952	0.956	0.942
	RESNET-KD	0.921	0.947	0.932	0.941	0.935
	TAE	0.933	0.985	0.949	0.993	0.965
F-score	DeepMLP-KD	0.872	0.969	0.947	0.949	0.934
	RESNET-KD	0.905	0.966	0.916	0.926	0.928
	TAE	0.922	0.985	0.944	0.993	0.961

表 XVII 比较了 IoT3 上传统教师-学生 KD 与无教师 TAE 的准确率和模型开销。TAE 以 98.5% 的准确率取得最高性能，同时不需要教师模型；它只需 67.72K 个训练参数和 22.54K 个推理参数，相较 DeepMLP-KD 和 ResNet-KD 的训练参数开销分别降低 36.0% 和 85.8%。

表 XVII：IoT3 上传统教师-学生 KD 与无教师 TAE 的比较。

方法	教师	教师大小	客户端大小	训练参数	推理参数	准确率
KD	DeepMLP	418 KB	199 KB	105.87K	27.27K	0.955
KD	ResNet	852 KB	199 KB	475.27K	27.27K	0.969
TAE	无	0	482 KB	67.72K	22.54K	0.985

VI. TAE 的特性

A. 变换算子比较

为进一步解释 TAE 的结果，我们比较 TAE、CTVAE、使用 TAE 变换算子的 CTVAE（CTVAE-tae），以及使用 CTVAE 变换算子的 TAE（TAE-ctvae），结果见表 XV。总体而言，TAE 的平均准确率和 F1 分数约比 CTVAE、CTVAE-tae 和 TAE-ctvae 高 1.5%。这说明 TAE 有效处理了 CTVAE 中观察到的后验坍塌问题。具体而言，TAE 用基于输入数据生成不同 CATR 的机制，替换了 CTVAE 损失函数中的参数技巧和 KL 散度项。此外，CTVAE-tae 的平均准确率略高于 CTVAE（0.886 对 0.883），说明使用 TAE 的变换算子比 CTVAE 的更有效。

**表 XV: TAE、CTVAE、使用 TAE 变换算子的 CTVAE (CTVAE-tae) 及使用 CTVAE 变换算子的 TAE (TAE-ctvae) 的比较。
 **

指标	方法	IoT1	IoT2	IoT3	IoT4	IoT5	IoT6	IoT7	NSL	UNSW	Cloud	Mal-1	Mal-2	Mal-3	平均
Accuracy	CTVAE	.933	.930	.965	.939	.948	.931	.934	.863	.741	.980	.513	.877	.921	.883
	CTVAE-tae	.923	.925	.966	.934	.975	.926	.952	.867	.737	.980	.517	.892	.922	.886
	TAE-ctvae	.919	.938	.973	.962	.941	.915	.956	.854	.736	.983	.516	.894	.913	.885
	TAE	.931	.933	.985	.949	.993	.959	.975	.873	.747	.987	.517	.914	.955	.901
F1-score	CTVAE	.915	.916	.960	.931	.937	.927	.923	.826	.673	.979	.433	.873	.929	.863
	CTVAE-tae	.895	.908	.964	.917	.974	.923	.940	.830	.706	.980	.439	.889	.930	.869
	TAE-ctvae	.893	.926	.971	.958	.926	.903	.947	.810	.700	.981	.439	.891	.922	.867
	TAE	.916	.922	.985	.944	.993	.949	.970	.844	.695	.987	.439	.912	.958	.886

B. 表示可视化

本小节通过在二维空间中可视化表示来分析 TAE。图 3 展示 TAE 在 IoT3 数据集上不同向量的分布。为简化表示，将潜在向量设为二维。图 3(a)、(b)、(c) 展示测试数据的模拟结果。图 3(a) 是用 PCA 降到二维的原始数据；图 3(b) 是测试集上的 TAE 潜在表示；图 3(c) 是测试集上的重构表示（原文图标注为 $\hat{y}^{(i)}$ ）。

可以观察到，测试集的原始数据样本相互重叠（图 3(a)）。在潜在空间中，数据样本仍然混合，说明直接使用潜在向量进行下游任务可能并不有效。然而，TAE 重构表示中的大多数数据样本已经很好地分离（图 3(c)）。例如，原始数据集中 Benign 与 UDP 的样本在测试集重叠，但在图 3(c) 中分离得多。此外，如图 3(c) 所示，重构表示中的大多数数据样本被收缩到一个小区域，使不同类别的数据样本更容易分类。

**图 3: **在 IoT3 数据集上使用 TAE 进行数据表示的模拟：(a) 原始数据，(b) 潜在向量 $\hat{e}^{(i)}$ ，(c) 重构表示 $\hat{z}^{(i)}$ 。

C. 表示质量

为进一步解释 TAE 的优越性能，我们遵循文献 [44] 的思想评估 TAE 中重构表示的质量。具体使用两个指标量化表示质量：类别均值之间的平均距离 d_{Bet} ，以及数据样本与其均值之间的平均距离 d_{Wit} 。此外，还引入新的调和指标表示质量： $representation-quality=d_{Bet}/d_{Wit}$ 。好的表示应使类别 c 的样本 $\hat{x}^{(i,c)}$ 更接近其均值 $\mu^{(c)}$ ，同时使类别均值之间的距离最大。换言之，表示质量值越大，表示越好。

表 XVIII 给出物联网数据集上原始数据 (Orig) $\hat{x}^{(i)}$ 与 TAE 重构表示 $\hat{z}^{(i)}$ 的表示质量。可以清楚看到，TAE 重构表示所得表示质量远大于原始数据所得值，这为重构表示优于原始数据的性能提供了更多证据。

表 XVIII: 原始数据与重构表示的表示质量。

数据	类间距离 Orig	类间距离 TAE	类内距离 Orig	类内距离 TAE	表示质量 Orig	表示质量 TAE
IoT1	1.1	2.9	1.6E-3	2.1E-3	7.0E+02	1.4E+03
IoT2	1.2	4.1	1.9E-3	704E-6	6.5E+02	5.8E+03
IoT3	1.1	3.8	2.1E-3	25E-6	5.5E+02	1.5E+05
IoT4	1.2	3.3	2.9E-3	1.4E-3	4.0E+02	2.4E+03
IoT5	1.2	3.7	4.0E-3	61E-6	2.9E+02	6.0E+04

数据	类间距离 Orig	类间距离 TAE	类内距离 Orig	类内距离 TAE	表示质量 Orig	表示质量 TAE
IoT6	4.1	5.2	13.8E-3	1.6E-3	3.0E+02	3.4E+03
IoT7	3.2	6.0	9.8E-3	1.6E-3	3.3E+02	3.8E+03

D. 重构表示与潜在表示

我们进行实验，比较 DT 分类器使用潜在表示 $\hat{e}^{(i)}$ 和重构表示 $\hat{z}^{(i)}$ 时的准确率。表 XIX 显示，在 7 个物联网数据集上， $\hat{z}^{(i)}$ 的准确率显著高于 $\hat{e}^{(i)}$ 。这是因为不同类别的 $\hat{e}^{(i)}$ 数据样本被投影到均值 $\mu^{(c)}$ 周围的小区域中（见式 (2)），导致频繁重叠（如图 3 所示）。相反，不同类别的 $\hat{z}^{(i)}$ 数据样本被映射到由 $\mu^{(c)}$ 定义的分隔区域（图 2）。这展示了 TAE 将重叠的潜在表示转变为可区分表示、帮助传统机器学习检测网络攻击的能力。

表 XIX: DT 使用潜在表示 $\hat{e}^{(i)}$ 与重构表示 $\hat{z}^{(i)}$ 的性能。

数据	IoT1	IoT2	IoT3	IoT4	IoT5	IoT6	IoT7	平均
$\hat{e}^{(i)}$	0.883	0.916	0.941	0.921	0.953	0.920	0.966	0.929
$\hat{z}^{(i)}$	0.931	0.933	0.985	0.949	0.993	0.959	0.975	0.961

E. TAE 的超参数

首先研究算法 1 中超参数 S 对 TAE 性能的影响（图 4(a)），表示向量维度 d_z 设为 10。当 S 太小时，DT 分类器得到的 TAE 准确率下降，因为 $\mu^{(c)}$ 的数据样本更接近，如算法 1 和图 2 所示。例如 $S=0.0001$ 时准确率低于 0.8，显著低于其 0.95 的平均值。

图 4(b) 展示潜在空间维度 d_z 的影响。当 d_z 太小时，DT 分类器上的 TAE 准确率下降。例如 $d_z=1$ 时 NSLKDD 准确率低于 0.8，而平均值为 0.86。只有 1 个维度时，编码器的信息丢失，降低 DT 分类器准确率。此外，由于算法 1 中的 PCA，当 d_z 超过输入数据维度时 TAE 模型无法运行。

**图 4: S 和 d_z 对 TAE 准确率的影响：(a) 调节参数 S ；(b) 调节参数 d_z 。

F. 模型复杂度

我们在 IoT2 数据集上报告所提 TAE 与 MAE、CTVAE 的复杂度实验结果。三种模型的编码器使用相同神经网络架构。测量模型大小（模型在硬盘上占用的存储空间，单位 MB）和推理时间（处理单个数据样本所需平均时间），结果见表 XX。三种模型都相对较小，规模约为 1 MB。MAE、CTVAE 和 TAE 的推理时间几乎相同，约为 0.26 μs ，因为测试阶段复杂度相同。因此 TAE 适合网络安全应用和潜在的物联网系统，模型大小约为 1 MB。

表 XX: IoT2 数据集上 MAE、CTVAE 和 TAE 的推理时间与模型大小。

指标	MAE	CTVAE	TAE
模型大小 (MB)	0.26	1.4	1.1
平均时间 (秒)	2.6E-07	2.9E-07	2.6E-07

VII. 结论

本文提出 TAE，它无需外部教师模型即可学习具有判别性的按类别表示。理论分析建立了完美表示的条件，并刻画了 TAE 经验风险低于使用固定类别中心的方法时的适用范围。在 13 个网络安全数据集上进行的大量实验表明，TAE 在物联网攻击检测中的平均准确率最高达 96.1%，在云入侵检测中达 98.7%。TAE 模型大小约为 1 MB，平均单样本推理时间为 0.26 μs ，为网络安全和物联网应用提供了有效且轻量的解决方案。

未来工作可以沿多个方向扩展。当前 CATR 只能用于 TAE 架构/模型,不能用于 MLP 和 MAE 等其他表示模型;可将 TAE CATR 扩展到其他表示学习模型。例如,可以开发一种方法选择 CATR 内的关键数据点,形成表示某个类别的一组码字。要把单个数据点投影到这组码字上,就需要把该数据点与组内所有关键数据点一起投影。第二,TAE 损失函数各组成部分之间存在权衡;开发能够针对每个数据集自动选择各项最优值的方法将很有益。最后,本文模型在网络安全数据集上进行了评估,未来还可将其扩展到计算机视觉和自然语言处理等其他领域。

附录

原文未设置附录。

参考文献

- [1] N. Alsabilah and D. B. Rawat, “基于联合粗糙集理论与 XGBoost 的网络入侵检测系统学习 (Joint rough set theory and xgboost-based learning for network intrusion detection system),” *IEEE IoT Journal*, vol. 12, no. 7, pp. 7930–7937, Apr. 2025.
- [2] Z. Wang, R. Zhou, S. Yang, D. He, and S. Chan, “一种基于自知识蒸馏的新型轻量级物联网入侵检测模型 (A novel lightweight IoT intrusion detection model based on self-knowledge distillation),” *IEEE IoT Journal*, vol. 12, no. 11, pp. 16 912–16 930, Jun. 2025.
- [3] S. Li, Y. Li, W. Han, X. Du, M. Guizani, and Z. Tian, “云计算环境中基于集成学习的恶意挖矿代码检测 (Malicious mining code detection based on ensemble learning in cloud computing environment),” *Simulation Modelling Practice and Theory*, vol. 113, p. 102391, Dec. 2021.
- [4] Y. Meidan, M. Bohadana, Y. Mathov, Y. Mirsky, A. Shabtai, D. Breitenbacher, and Y. Elovici, “N-BaIoT——使用深度自编码器的基于网络的物联网僵尸网络攻击检测 (N-baiot—network-based detection of IoT botnet attacks using deep autoencoders),” *IEEE Pervasive Computing*, vol. 17, no. 3, pp. 12–22, Mar. 2018.
- [5] Y. Wu, L. Zhang, L. Yang, F. Yang, L. Ma, Z. Lu, and W. Jiang, “物联网入侵检测: 一种锚图聚类方法 (Intrusion detection for internet of things: An anchor graph clustering approach),” *IEEE Transactions on Information Forensics and Security*, vol. 20, pp. 1965–1980, Feb. 2025.
- [6] P. V. Dinh, Q. U. Nguyen, D. T. Hoang, D. N. Nguyen, S. P. Bao, and E. Dutkiewicz, “物联网系统入侵检测的约束孪生变分自编码器 (Constrained twin variational auto-encoder for intrusion detection in IoT systems),” *IEEE IoT Journal*, vol. 11, no. 8, pp. 14 789–14 803, Apr. 2024.
- [7] M. Nakip and E. Gelenbe, “用于入侵检测系统的在线自监督深度学习 (Online self-supervised deep learning for intrusion detection systems),” *IEEE Transactions on Information Forensics and Security*, vol. 19, pp. 5668–5683, May 2024.
- [8] L. Vu, V. L. Cao, Q. U. Nguyen, D. N. Nguyen, D. T. Hoang, and E. Dutkiewicz, “学习用于物联网异常检测的潜在表示 (Learning latent representation for IoT anomaly detection),” *IEEE Transactions on Cybernetics*, vol. 52, no. 5, pp. 3769–3782, May 2022.
- [9] I. Goodfellow, Y. Bengio, and A. Courville, *深度学习 (Deep Learning)*. The MIT Press, 2016.
- [10] K. Simonyan and A. Zisserman, “用于大规模图像识别的非常深的卷积网络 (Very deep convolutional networks for large-scale image recognition),” Proc. ICLR, San Diego, CA, USA, 2015, pp. 1–10.
- [11] S. Rahman, S. Pal, J. Yearwood, and C. Karmakar, “部署于内存受限物联网设备的基于深度学习 ECG 噪声分类模型的性能分析 (Analysing performances of dl-based ecg noise classification models deployed in memory-constraint IoT-enabled devices),” *IEEE Transactions on Consumer Electronics*, pp. 704–714, Feb. 2024.

- [12] U. C. Akuthota and L. Bhargava, “基于 Transformer 的物联网网络入侵检测 (Transformer-based intrusion detection for IoT networks),” **IEEE IoT Journal**, vol. 12, no. 5, pp. 6062 – 6067, Mar. 2025.
- [13] B. Pal, M. S. Islam, and A. W.-C. Liew, “可信深度物联网攻击检测的校准不确定性估计 (Calibrated uncertainty estimation for trustworthy deep IoT attack detection),” **IEEE Transactions on Dependable and Secure Computing**, vol. 22, no. 6, pp. 7571 – 7584, Dec. 2025.
- [14] M. Ali Lodhi, M. S. Obaidat, L. Wang, K. Mahmood, K. Ibrahim Qureshi, J. Chen, and K.-F. Hsiao, “用于 LoRaWAN 高效信道选择的微型机器学习 (Tiny machine learning for efficient channel selection in LoRaWAN),” **IEEE IoT Journal**, vol. 11, no. 19, pp. 30 714 – 30 724, Oct. 2024.
- [15] K. S. Prasad, E. L. Lydia, M. Rajesh, M. Radhika, J. V. N. Ramesh, N. Neelima, and R. Pokuri, “通过基于注意力的堆叠自编码器和优化算法增强网络安全, 用于检测和缓解物联网辅助网络中的攻击 (Augmenting cybersecurity through attention based stacked autoencoder with optimization algorithm for detection and mitigation of attacks on IoT assisted networks),” **Scientific Reports**, vol. 14, no. 1, p. 30833, Dec. 2024.
- [16] M. Al-Qatf, Y. Lasheng, M. Al-Habib, and K. Al-Sabahi, “结合稀疏自编码器与 SVM 的网络入侵检测深度学习方法 (Deep learning approach combining sparse autoencoder with SVM for network intrusion detection),” **IEEE Access**, vol. 6, no. 1, pp. 52 843 – 52 856, Sept. 2018.
- [17] H. Wu and M. Flierl, “基于向量量化的自编码器正则化 (Vector quantization-based regularization for autoencoders),” *Proc. AAAI*, vol. 34, no. 04, Palo Alto, California, 2020, pp. 6380 – 6387.
- [18] W. Luo, J. Li, J. Yang, W. Xu, and J. Zhang, “用于图像分类的卷积稀疏自编码器 (Convolutional sparse autoencoders for image classification),” **IEEE Transactions on Neural Networks and Learning Systems**, vol. 29, no. 7, pp. 3289 – 3294, Jul. 2018.
- [19] Y. Takida, W.-H. Liao, C.-H. Lai, T. Uesaka, S. Takahashi, and Y. Mitsufuji, “通过广义方差参数化防止 VAE 中的过度平滑 (Preventing oversmoothing in VAE via generalized variance parameterization),” **Neurocomputing**, vol. 509, pp. 137 – 156, Oct. 2022.
- [20] I. Evron, O. Onn, T. Weiss, H. Azeroual, and D. Soudry, “纠错码中码字到类别分配的作用: 一项实证研究 (The role of codeword-to-class assignments in error-correcting codes: An empirical study),” *AISTATS*, Palau de Congressos, Valencia, Spain, 2023, pp. 8053 – 8077.
- [21] S. Yang, P. Luo, C. G. Loy, K. W. Shum, and X. Tang,
- [21] S. Yang, P. Luo, C. G. Loy, K. W. Shum, and X. Tang, “使用目标编码的深度表示学习 (Deep representation learning with target coding),” *Proc. AAAI*, vol. 29, no. 1, Austin, Texas, 2015.
- [22] G. Hinton, O. Vinyals, and J. Dean, “蒸馏神经网络中的知识 (Distilling the knowledge in a neural network),” *arXiv preprint arXiv:1503.02531*, 2015.
- [23] J. Jang, S. Kim, K. Yoo, C. Kong, J. Kim, and N. Kwak, “自蒸馏的自监督表示学习 (Self-distilled self-supervised representation learning),” *Proc. WACV*, Waikoloa, Hawaii, 2023, pp. 2829 – 2839.
- [24] J. Yeo, S. Cha, J. Song, H. Jin, and T. Kim, “ATAS: 用于增强开放词汇密集预测的任意到任意自蒸馏 (Atas: any-to-any self-distillation for enhanced open-vocabulary dense prediction),” *Proc. ICCV*, Honolulu, Hawaii, 2025, pp. 20 390 – 20 400.
- [25] S. Kim, R. Xiao, M.-I. Georgescu, S. Alaniz, and Z. Akata, “COSMOS: 用于视觉语言预训练的跨模态自蒸馏 (Cosmos: cross-modality self-distillation for vision language pre-training),” *Proc. CVPR*, Nashville, Tennessee, 2025, pp. 14 690 – 14 700.

- [26] D. McElfresh, S. Khandagale, J. Valverde, V. Prasad C, G. Ramakrishnan, M. Goldblum, and C. White, “神经网络何时在表格数据上胜过提升树? (When do neural nets outperform boosted trees on tabular data?),” *Proc. NeurIPS*, vol. 36, New Orleans Convention Center, 2023, pp. 76 336 – 76 369.
- [27] W. L. Costa, A. L. Portela, and R. L. Gomes, “基于雾计算和云计算的异构智能环境特征感知 DDoS 检测 (Features-aware DDoS detection in heterogeneous smart environments based on fog and cloud computing),” **International Journal of Communication Networks and Information Security**, vol. 13, no. 3, pp. 491 – 498, Dec. 2021.
- [28] Y. Yin, J. Jang-Jaccard, W. Xu, A. Singh, J. Zhu, F. Sabrina, and J. Kwak, “IGRF-RFE: 用于 UNSW-NB15 数据集上基于 MLP 的网络入侵检测的混合特征选择方法 (Igrf-rfe: a hybrid feature selection method for mlp-based network intrusion detection on unsw-nb15 dataset),” **Journal of Big Data**, vol. 10, no. 1, pp. 1 – 26, Feb. 2023.
- [29] G. Lee, S.-W. Kim, and M. Jeon, “利用 1D-CNN 模型对 MEMS 低采样率振动信号进行 IIoT 系统机械价值估计的方法 (Machinery value estimation method based on iiot system utilizing 1d-cnn model for low sampling rate vibration signals from mems),” **IEEE IoT Journal**, vol. 10, no. 14, pp. 12 261 – 12 275, Jul. 2023.
- [30] S. Cherfi, A. Lemouari, and A. Boulaiche, “用于保护物联网网络的基于 MLP 的入侵检测 (Mlp-based intrusion detection for securing iot networks),” **Journal of Network and Systems Management**, vol. 33, no. 1, p. 20, Dec. 2025.
- [31] A. Razavi, A. v. d. Oord, B. Poole, and O. Vinyals, “使用 Delta-VAE 防止后验坍塌 (Preventing posterior collapse with delta-vaes),” *ICLR*, New Orleans, Louisiana, United States, 2019, pp. 1 – 11.
- [32] M. Tavallaee, E. Bagheri, W. Lu, and A. A. Ghorbani, “KDD Cup 99 数据集的详细分析 (A detailed analysis of the kdd cup 99 data set),” *Proc. CISDA*, Ottawa, ON, Canada, 2009, pp. 1 – 6.
- [33] N. Moustafa and J. Slay, “UNSW-NB15: 用于网络入侵检测系统的综合数据集 (UNSW-NB15 network data set) (Unsw-nb15: a comprehensive data set for network intrusion detection systems),” *Proc. MilCIS*, Canberra, ACT, Australia, 2015, pp. 1 – 6.
- [34] S. Garcia, A. Parmisano, and M. J. Erquiaga, “IoT-23: 带有恶意和良性物联网网络流量的标注数据集 (Iot-23: a labeled dataset with malicious and benign iot network traffic),” *Stratosphere Lab.*, Praha, Czech Republic, Tech. Rep., 2020.
- [35] R. Kumar, S. P. Lal, and A. Sharma, “检测云中的拒绝服务攻击 (Detecting denial of service attacks in the cloud),” *Proc. Intl. Conf. Depend. Auto. Secur. Comput.*, Auckland, New Zealand: IEEE, 2016, pp. 309 – 316.
- [36] J. G. Carbonell, R. S. Michalski, and T. M. Mitchell, “机器学习概述 (An overview of machine learning),” **Machine Learning**, vol. 1, pp. 3 – 23, Jan. 1983.
- [37] C. Zhang, S. Bengio, M. Hardt, B. Recht, and O. Vinyals, “理解深度学习需要重新思考泛化 (Understanding deep learning requires rethinking generalization),” *Proc. ICLR*, Toulon, France, 2017, pp. 1 – 15.
- [38] I. T. Jolliffe, **用于特殊类型数据的主成分分析 (Principal component analysis for special types of data)**, Springer, 2002.
- [39] Y. Yu and N. Bian, “一种使用少样本学习的入侵检测方法 (An intrusion detection method using few-shot learning),” **IEEE Access**, vol. 8, pp. 49 730 – 49 740, Mar. 2020.
- [40] S. learn developers, “生成斑块 (Make blobs),” https://scikit-learn.org/stable/modules/generated/sklearn.datasets.make_blobs.html, n.d., accessed: 2025-11-20.

- [41] J. Park, J. Lee, and D. Sim, “使用 1D 和 2D 滤波器的低复杂度 CNN 超分辨率 (Low-complexity CNN with 1d and 2d filters for super-resolution),” **Journal of Real-Time Image Processing**, vol. 17, no. 6, pp. 2065 – 2076, Jun. 2020.
- [42] D. P. Kingma and J. Ba, “ADAM: 随机优化方法 (Adam: A method for stochastic optimization),” ICLR (Poster), 2015.
- [43] C. Xiang, P. C. Yong, and L. S. Meng, “使用贝叶斯聚类和决策树设计多级混合入侵检测系统分类器 (Design of multiple-level hybrid classifier for intrusion detection system using bayesian clustering and decision trees),” **Pattern Recognition Letters**, vol. 29, no. 7, pp. 918 – 924, May 2008.
- [44] P. Xanthopoulos, P. M. Pardalos, T. B. Trafalis, P. Xanthopoulos, P. M. Pardalos, and T. B. Trafalis, “线性判别分析 (Linear discriminant analysis),” **Robust Data Mining**, pp. 27 – 33, Jan. 2013.